

Forecasting de producción eléctrica mensual

Juan Daniel Barboza

Maestría en Ciencias de la Inteligencia Artificial

Pregunta central

¿Un modelo con estructura estacional explícita puede superar a Machine Learning y a una referencia anual simple?

Serie mensual

397 observaciones

Horizonte final

24 meses

Modelos comparados

2 categorías


Problema y dataset

Objetivo


Pronosticar el índice mensual de producción eléctrica IPG2211A2N a partir de su historial.

- ▶ **397 meses:** 1985–2018.
- ▶ Frecuencia mensual y objetivo positivo.
- ▶ Sin faltantes ni fechas duplicadas.
- ▶ Es un **índice**, no energía en unidades físicas.

Fuente: Time Series Datasets (Kaggle). Equivalente: FRED IPG2211A2N.



Qué aprendimos de la serie




Tres señales

- ▶ Tendencia creciente de largo plazo.
- ▶ Estacionalidad anual clara: período **12**.
- ▶ Amplitud asociada al nivel de la serie.

Decisión

Ajustar sobre $\log(y)$ y volver a la escala original antes de medir errores.

Protocolo temporal




Segmento	<i>n</i>	Uso
Train	349	Ajustar candidatos
Validation	24	Seleccionar
Test	24	Evaluar una vez

Control metodológico

Mismo historial, mismo origen y mismo horizonte de 24 meses para todos. No se comparan ventanas con distinto número de folds ni fechas iniciales diferentes.

Modelos y pipeline de pronóstico



Referencia

Naive estacional: repite el valor observado 12 meses antes.


SARIMA · estadístico

Seleccionado: $(2, 0, 2)(1, 1, 1)_{12}$.
Modela dependencia y estacionalidad explícitamente.

XGBoost · ML

15 variables: rezagos, ventanas móviles y calendario. Pronóstico **recursivo** sin valores futuros reales.

Selección en validation




Resultado

SARIMA fue mejor en las tres métricas:

- ▶ RMSE: **3,0453**
- ▶ MAE: **2,3011**
- ▶ MAPE: **2,2756 %**


Se evaluaron 144 configuraciones SARIMA y 64 de XGBoost. La decisión quedó fijada antes de abrir test.

Pronóstico final sobre test



Los dos modelos siguen la estacionalidad; XGBoost suaviza más los extremos. La banda corresponde al intervalo de confianza del 95 % de SARIMA.

Comparación final de métricas




SARIMA vs. baseline

- ▶ RMSE: $-33,29\%$
- ▶ MAE: $-22,03\%$
- ▶ MAPE: $-20,35\%$

Lectura de XGBoost

Reduce RMSE, pero queda levemente peor que el baseline en MAE y MAPE: la mejora no es consistente.

Diagnóstico de errores de SARIMA



Hallazgos

- ▶ Error medio: $-0,7713$.
- ▶ Ljung-Box: $p = 0,3696$ a 6 meses.
- ▶ Ljung-Box: $p = 0,3818$ a 12 meses.

No hay evidencia significativa de autocorrelación. Los desvíos de cola se interpretan con cautela: solo hay 24 errores.

Conclusiones

Modelo recomendado

SARIMA(2, 0, 2)(1, 1, 1)₁₂
Ajustado sobre $\log(y)$ · MAPE final: **3,3093 %**

Evidencia

- ▶ Ganó en validation.
- ▶ Confirmó la ventaja en test.
- ▶ Superó claramente al baseline.

Interpretación

- ▶ La estacionalidad anual domina.
- ▶ SARIMA representa mejor esa estructura.
- ▶ XGBoost suaviza picos y valles.

Límite

- ▶ Horizonte final de 24 meses.
- ▶ Diagnóstico residual descriptivo.
- ▶ No se ajustó nada después de test.

Una evaluación temporal justa sostuvo la misma conclusión en validation y test.